

Mini Porject - Digital Skill Fair 41.0 Faculty of Data by Dibimbing.id

EKSPLORASI DATA KELULUSAN MAHASISWA

Oleh : Charlene Callystha Maelissa

LATAR BELAKANG & TUJUAN

Kelulusan mahasiswa merupakan salah satu indikator penting dalam mengevaluasi efektivitas sistem pendidikan tinggi. Dengan mengeksplorasi data kelulusan, dapat ditemukan pola dan hubungan antar variabel yang dapat menjadi dasar perbaikan kebijakan akademik. Studi ini bertujuan untuk menggali insight awal melalui visualisasi data, seperti heatmap, guna memahami faktor-faktor yang berpotensi memengaruhi kelulusan.

DESKRIPSI DATASET


	IPK	SKS	Frekuensi Kehadiran	Jumlah MK Ulang	Keikutsertaan Organisasi	Kelulusan
0	2.75	141.0	79.0	3.0	0	1
1	3.90	148.0	91.0	0.0	1	1
2	3.46	141.0	84.0	3.0	1	1
3	3.20	113.0	56.0	2.0	0	0
4	2.31	139.0	65.0	0.0	1	0
...	...	...	...	...	...	...
103	2.99	120.0	78.0	0.0	0	0
104	2.99	120.0	78.0	NaN	0	0
105	2.99	120.0	78.0	0.0	0	0
106	2.99	NaN	78.0	0.0	0	0
107	2.99	120.0	NaN	0.0	0	0

108 rows × 6 columns

Dataset ini merupakan data fiktif yang disusun untuk tujuan eksplorasi dan pembelajaran. Dataset ini berisi data kelulusan mahasiswa yang terdiri 107 baris dan 6 variabel yaitu IPK, SKS, Frekuensi Kehadiran, Jumlah MK ulang, Keikutsertaan organisasi, Kelulusan.

DATA CLEANING

Untuk memulai analisis, saya mengimport beberapa library utama seperti pandas untuk membaca dataset serta menampilkannya dalam bentuk DataFrame, seaborn dan matplotlib untuk visualisasi data. Dataset dimuat menggunakan fungsi `pd.read.csv()`.



```
[1] # Mengimport library pandas untuk membaca dataset dan eksplorasi data
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns


[2] # Memasukkan file dataset yang akan digunakan
from google.colab import files
uploaded = files.upload()

Choose Files Data_Kelulusan_(2).csv
• Data_Kelulusan_(2).csv(text/csv) - 2117 bytes, last modified: 7/28/2025 - 100% done
Saving Data_Kelulusan_(2).csv to Data_Kelulusan_(2).csv

[3] # baca dataset csv menggunakan syntax pd.read_csv()
df = pd.read_csv('Data_Kelulusan_(2).csv')

# Menampilkan dataset dalam bentuk tabel dengan memanggil df
df
```

	IPK	SKS	Frekuensi Kehadiran	Jumlah MK Ulang	Keikutsertaan Organisasi	Kelulusan
0	2.75	141.0	79.0	3.0	0	1
1	3.90	148.0	91.0	0.0	1	1
2	3.46	141.0	84.0	3.0	1	1
3	3.20	113.0	56.0	2.0	0	0
4	2.31	139.0	65.0	0.0	1	0
...	...	...	...	...	...	...
103	2.99	120.0	78.0	0.0	0	0
104	2.99	120.0	78.0	NaN	0	0
105	0.00	100.0	70.0	0.0	0	0



DATA CLEANING

```
# Menampilkan ringkasan data untuk memahami struktur data
df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 108 entries, 0 to 107
Data columns (total 6 columns):
#   Column                Non-Null Count  Dtype  
---  -
0   IPK                    108 non-null   float64
1   SKS                    107 non-null   float64
2   Frekuensi Kehadiran    107 non-null   float64
3   Jumlah MK Ulang        107 non-null   float64
4   Keikutsertaan Organisasi 108 non-null   int64  
5   Kelulusan              108 non-null   int64  
dtypes: float64(4), int64(2)
memory usage: 5.2 KB

[ ] df['Keikutsertaan Organisasi'] = df['Keikutsertaan Organisasi'].map(str)
df['Kelulusan'] = df['Kelulusan'].map(str)
```


```
3. Mengecek Missing Value

# Mengecek missing value
df.isna().sum()


0
IPK      0
SKS      1
Frekuensi Kehadiran  1
Jumlah MK Ulang      1
Keikutsertaan Organisasi  0
Kelulusan            0

dtype: int64
```

Untuk memahami struktur data saya menggunakan fungsi `df.info()` untuk menampilkan ringkasan struktur data. Pada dataset variabel Keikutsertaan Organisasi dan Kelulusan awalnya bertipe integer namun saya konversi menjadi tipe string untuk memudahkan eksplorasi data. Kemudian juga saya menggunakan fungsi `df.isna().sum()` untuk mengetahui jumlah data kosong pada tiap variabel, seperti pada gambar terdapat masing-masing satu missing value pada variabel sks, frekuensi kehadiran dan jumlah MK ulang.



DATA CLEANING



```
[ ] # cek statistical summary  
df.describe()
```

	IPK	SKS	Frekuensi Kehadiran	Jumlah MK Ulang
count	108.000000	107.000000	107.000000	107.000000
mean	2.943889	129.700935	76.971963	1.439252
std	0.572337	12.236826	13.655780	1.125834
min	2.010000	110.000000	50.000000	0.000000
25%	2.400000	120.000000	67.500000	0.000000
50%	2.990000	131.000000	78.000000	1.000000
75%	3.437500	141.000000	86.000000	2.000000
max	3.970000	149.000000	98.000000	3.000000

```
# cek statistical summary pada variabel tertentu  
df['Keikutsertaan Organisasi'].describe()
```

Keikutsertaan Organisasi	
count	108
unique	2
top	0
freq	54

dtype: object

Selain memahami struktur data, saya juga menggunakan fungsi `df.describe()` untuk melihat ringkasan statistik dari variabel numerik. Pada dataset ipk minimal mahasiswa 2.0 dan tertinggi 3.97. Kemudian saya melakukan ringkasan statisik pada variabel keikutsertaan organisasi untuk melihat pola data pada variabel tersebut, dapat dillihat bahwa variabel keikutsertaan organisasi memiliki 2 jawaban unik dengan jawaban terbanyak adalah 0 dengan frekuensi sebanyak 54.

DATA CLEANING


```
[ ] # Mengatasi Missing Value
for column in df.columns:
    if df[column].dtypes == 'object':
        df[column].fillna(df[column].mode()[0], inplace=True)
    else:
        df[column].fillna(df[column].mean(), inplace=True)
```

```
# cek kembali missing value
df.isna().sum()
```

	0
IPK	0
SKS	0
Frekuensi Kehadiran	0
Jumlah MK Ulang	0
Keikutsertaan Organisasi	0
Kelulusan	0

dtype: int64

Langkah ini dilakukan untuk menangani data yang hilang (missing value) pada setiap variabel dalam dataset. Jika kolom bertipe kategorikal (object), nilai kosong diisi dengan modus dari variabel tersebut. Sedangkan jika nilai bertipe numerik, nilai kosong diisi dengan mean dari variabel tersebut. Kemudian dilakukan pengecekan ulang untuk memastikan data sudah bersih dari missing value.



DATA CLEANING

```
[ ] # Mengecek apakah ada duplikat di seluruh kolom
    check_duplicate = df.duplicated().sum()
    print(f"Jumlah data yang duplikat = {check_duplicate}")

➔ Jumlah data yang duplikat = 5

[ ] # Handling Duplicate
    df = df.drop_duplicates()

[ ] # Mengecek duplicate setelah di-handle
    handle_duplicate = df.duplicated().sum()
    print(f"Jumlah data yang duplikat = {handle_duplicate}")

➔ Jumlah data yang duplikat = 0

[ ] print(handle_duplicate)

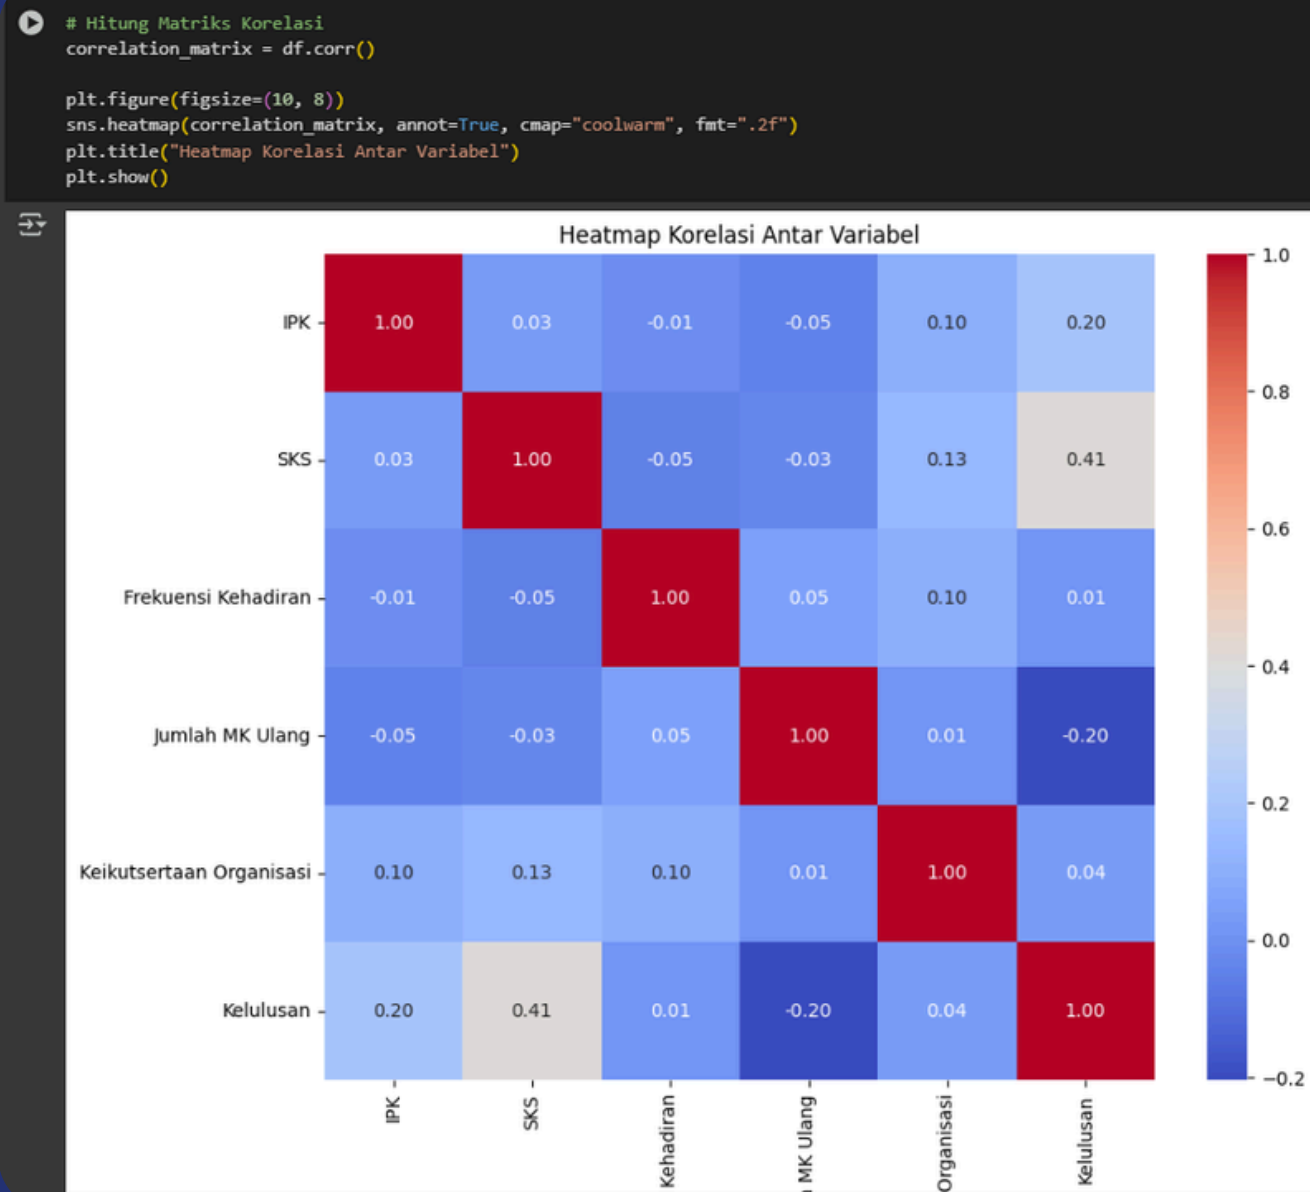
➔ 0
```

Pada tahap ini dilakukan pemeriksaan dan penghapusan terhadap data duplikat dalam dataset. Fungsi `df.duplicated().sum()` digunakan untuk menghitung jumlah baris yang identik secara keseluruhan. Pada dataset terdapat 5 baris yang duplikat maka dihapus menggunakan fungsi `df.drop_duplicates()`. Setelah penghapusan, dilakukan pemeriksaan ulang.




DATA CLEANING

Langkah selanjutnya membuat visualisasi untuk melihat korelasi antar variabel numerik dalam dataset dengan menggunakan fungsi `df.corr()`. Kemudian menggunakan `sns.heatmap()` fungsi dari library seaborn untuk membuat heatmap.



INSIGHT DARI HEATMAP




- SKS memiliki korelasi paling tinggi terhadap kelulusan dengan nilai 0.41. Artinya semakin banyak SKS yang diambil, semakin besar peluang mahasiswa untuk lulus.
- IPK juga memiliki korelasi positif terhadap kelulusan dengan nilai 0.20 berarti semakin tinggi IPK, peluang kelulusan cenderung meningkat.
- Namun jumlah mata kuliah yang ulang berkorelasi negatif terhadap kelulusan dengan nilai -0.29 berarti semakin banyak MK yang diulang, peluang kelulusan menurun. Ini bisa jadi sinyal risiko akademik.
- Kehadiran tidak menunjukkan pengaruh yang signifikan terhadap kelulusan ditandai dengan nilai korelasi yang rendah 0.01.
- Keikutsertaan organisasi tampaknya tidak berdampak langsung pada kelulusan ditandai dengan nilai korelasi yang rendah 0.04

KESIMPULAN & REKOMENDASI


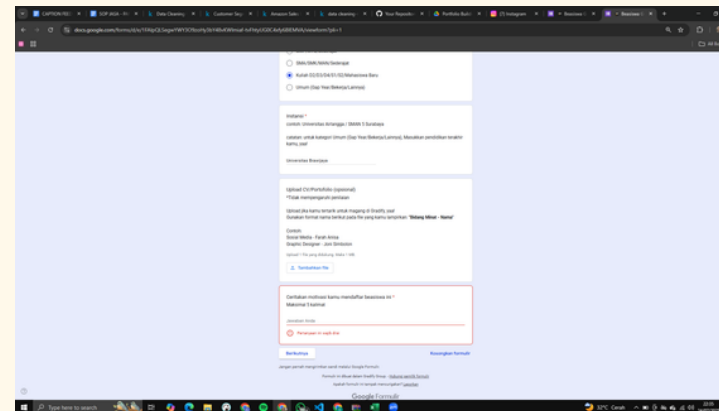





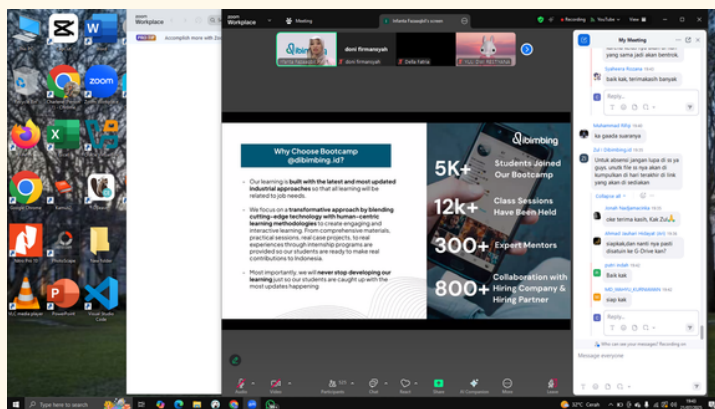
- Hasil analisis menunjukkan bahwa beberapa variabel memiliki hubungan terhadap kelulusan mahasiswa, dengan faktor akademik seperti SKS dan IPK menunjukkan hubungan yang relatif lebih kuat dibandingkan variabel lainnya. Sementara itu, variabel non-akademik seperti frekuensi kehadiran dan keikutsertaan organisasi tampak memiliki pengaruh yang sangat rendah. Jumlah mata kuliah ulang juga menunjukkan adanya hubungan negatif terhadap kelulusan
- Institusi disarankan untuk lebih memprioritaskan dukungan akademik seperti manajemen SKS dan peningkatan IPK mahasiswa. Selain itu, perlu ada pemantauan dan intervensi terhadap mahasiswa yang memiliki kecenderungan mengulang mata kuliah. Evaluasi lebih lanjut juga dapat dilakukan terhadap program kegiatan non-akademik agar lebih selaras dengan capaian akademik mahasiswa.

REFLEKSI & KESAN PESAN ACARA

Mengikuti Digital Skill Fair 41.0 Faculty of Data dari Dibimbing.id memberikan saya pemahaman lebih mendalam tentang proses eksplorasi data dan pentingnya data cleaning sebelum masuk ke tahap modeling. Saya jadi menyadari bahwa data science tidak hanya soal algoritma, tapi juga soal memahami konteks data dengan benar. Semoga acara seperti ini terus diadakan dan makin banyak materi praktikal yang dibahas. Terima kasih untuk mentor dan tim Dibimbing.id.



DOKUMENTASI



TERIMA KASIH

Terima kasih atas perhatiannya.
Kritik, saran, maupun diskusi lanjutan
sangat saya harapkan untuk
pengembangan diri ke depannya.
Silakan terhubung dengan saya melalui
LinkedIn untuk berdiskusi lebih jauh.



@Charlene Callystha Maelissa



@charleneee.____



callysthamaelissa@gmail.com